Zpracování a vizualizace dat v prostředí Python

Získávání dat a datová perzistence

Zdeněk VAŠÍČEK
Fakulta Informačních Technologií, Vysoké Učení Technické v Brně
Brno, Czech Republic
vasicek@fit.vutbr.cz

Obsah

- Získávání dat (volně dostupná data, data scraping)
  - nestrukturovaná / špatně strukturovaná data
  - částečně / plně strukturovaná data
- Typické formáty pro výměnu dat a jejich zpracování
  - textové a binární datové formáty
- Serializace a uchovávání dat
  - souborově orientované úložiště
  - databázové systémy

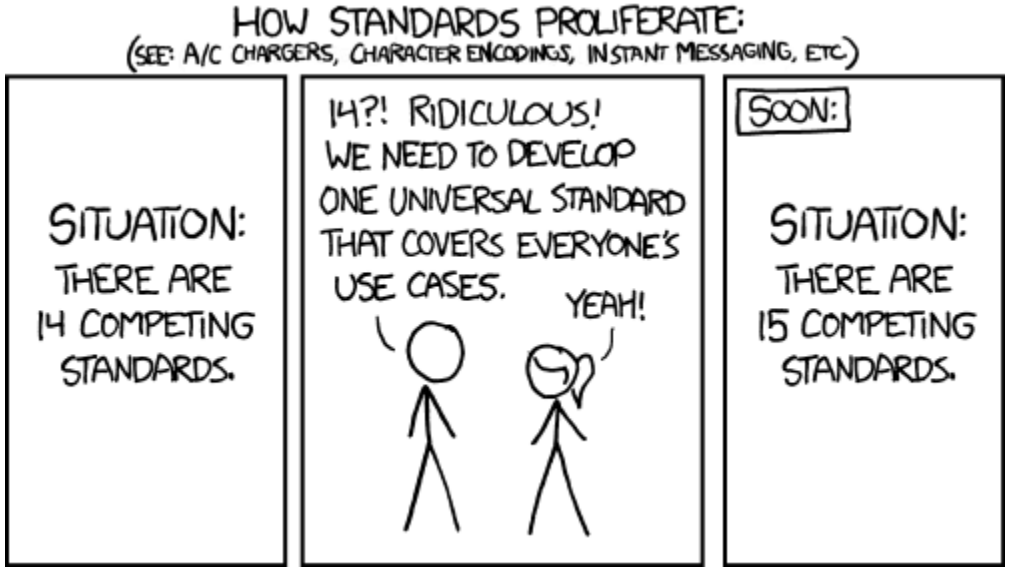

https://xkcd.com/927

Členění dat z pohledu jejich struktury

Strojově čitelná data lze s ohledem na automatické počítačové zpracování rozdělit na

- Strukturovaná data
  - Organizovaná data s daným modelem (snadná adresace položek, snadné vyhledávání).
  - Lze uchovávat v klasických relačních databázích (SQL DB založených na tabulkách).
- Částečně strukturovaná data
  - Jsou typem strukturovaných dat, ale jednotlivé entity mohou mít svůj vlastní organizační vzor.
  - Formát XML a JSON patří mezi typické výměnné formáty této kategorie dat.
  - Nepasují do tradičních relačních databází, vhodné spíše pro dokumentově orientované NoSQL databáze uchovávající dvojice klíč-hodnota.
- Nestrukturovaná data
  - Nemají definovaný model nebo organizaci (netriviální vyhledávání).
  - Typicky se jedná o data jejichž konzumentem je člověk (tj. multimediální soubory, maily, chat, webový obsah, ale i PDF, kde je důraz na vizuální stránku).
  - Nevhodné pro relační DB, spíše dokumentově orientované databáze.

Konkrétní příklady

- Nestrukturovaná/špatně strukturovaná data
  - PDF (v této podobě vyžaduje extrémní úsilí aby bylo možné strojově zpracovat – přesnost dat?)
    https://kod.brno.cz/dataset/.../download/cizinci-v-brne-kniha.pdf (výsledky výzkumu, link z data.gov.cz)
  - HTML layout (změna rozložení = předělání skriptu)
    http://portal.chmi.cz/historicka-data/pocasi/uzemni-teploty
    https://www.mpsv.cz/prehled-o-vyvoji-castek-minimalni-mzdy
  - Word dokument (automaticky extrémně obtížně zpracovatelné)
    https://www.mpsv.cz/web/cz/zprava-o-zakladnich-tendencich-prijmove-a-vydajove...
- Částečně strukturovaná data
  - XLSX (potřebujeme další meta informace, abychom správně načetli obsah)
    https://www.mpsv.cz/web/cz/zprava-o-zakladnich-tendencich-prijmove-a-vydajove...
  - CSV
    http://portal.chmi.cz/historicka-data/pocasi/denni-data/Denni-data-dle-z.-123-1998-Sb
  - XML bez schématu
    http://portal.chmi.cz/files/portal/docs/uoco/web_generator/AIMdata_hourly.xml
- Strukturovaná data
  - XML vybavený schématem (XSD)
    http://wwwinfo.mfcr.cz/cgi-bin/ares/darv_std.cgi?ico=00216305
  - JSON vybavený schématem (JSON-schema)
    https://data.gov.cz/datov%C3%A1-sada?iri=https%3A%2F%2Fdata.gov.cz%2Fzdroj%2Fdatov%C3%A9-sady%2Fhttp---opendata.praha.eu-api-3-action-package_show-id-cerpani-rozpoctu-mhmp-2021

Zdroje dat, další informace

- Příklady zdrojů dat v ČR
  - Portál veřejných dat https://data.gov.cz/
  - Datové sady ministerstev https://opendata.mzcr.cz/, https://data.mfcr.cz/, https://opendata.mzp.cz/, https://data.msmt.cz/ (0), http://data.mmr.cz/
  - Datový portál města Brna https://data.brno.cz/, Prahy https://opendata.praha.eu/ , …
  - Datové služby KN (adresy, správní jednotky, budovy, …) https://services.cuzk.cz/, https://atom.cuzk.cz/
  - Mapové služby KN (vektorová data) https://geoportal.cuzk.cz/
  - Meteorologická data http://portal.chmi.cz/
  - Polohy vozidel IDS JMK https://mapa.idsjmk.cz/ , IDS Praha https://mapa.pid.cz/
- Situace s daty v ČR
  - viz https://www.irozhlas.cz/zpravy-tag/datova-zurnalistika
- Další informace
  - viz https://stevesie.com/docs/pages/is-data-scraping-legal

Získávání dat z webových a jiných zdrojů

Přehled možností

Prerekvizity » princip HTTP/HTTPs

Umístění zdroje dat

- Data jsou typicky dostupná pod nějakou URL (Uniform Resource Locator) adresou
  - řetězec ASCII znaků (vyjma mezery) s definovanou strukturou, který slouží k přesné specifikaci umístění zdrojů informací (ve smyslu dokument nebo služba) na Internetu.
- Formát URL:

  protokol://server.doména_druhého_řádu.generická_doména:port/umístění_na_serveru?query_string#kotva

  - příklad: https://www.httpbin.org/get?param1=value1&param2=value2%26value3+value4#intro
- Kódování URL:
  - Znaky mimo ASCII jsou nahrazeny znakem `%` následovaným dvěmi hexa číslicemi
  - Mezera je nahrazena znakem `+` nebo pomocí `%20`
- Práce s URL adresou v Python:
  - podpora pro parsování, vytváření a manipulaci s URL je součástí vestavěného modulu **urllib.parse**

Operace nad URL adresou

```
import urllib.parse as up
```

- Parsování URL a QS

```
url = up.urlparse('https://user:password@www.httpbin.org:443/get?param1=value1&param2=value2%26value3+value4#intro')
#ParseResult(scheme='https', netloc='user:password@www.httpbin.org:443', path='/get', params='',
query='param1=value1&param2=value2%26value3+value4', fragment='intro')
url.username, url.password, url.hostname, url.port
#('user', 'password', 'www.httpbin.org', 443)
up.parse_qs(url.query)
#{'param1': ['value1'], 'param2': ['value2&value3 value4']}
```

- Sestavení URL a změna jednotlivých částí

```
newurl = url._replace(netloc='httpbin.org', query = up.urlencode({'param1':'new/val1'}))
parse.urlunparse(newurl)  #'https://httpbin.org/get?param1=new%2Fval1#intro'
```

- Další operace:
  - kódování query a path: **urlencode**, **quote**, **quote_plus**, nahrazení path: **urlsplit**, **urljoin**

Získávání dat v prostředí Python

- Podpora pro získávání dat z webových služeb (HTML, REST, GraphQL, SOAP, …)

* viz také high-level framework scapy a selenium

Protokol	Modul	Popis
HTTP/1.1, HTTPs/1.1	**urllib.request** (vestavěný)	dobrá funkcionalita, horší API
	requests (externí)	propracované API, široká funkcionalita, podpora REST
HTTP/2, HTTPs/2	**httpx** (externí)	beta verze, asynchronní dotazy, API jako requests
SOAP, WSDL	**zeep** (externí)	podpora WSDL, XSD schémat
gRPC	**grpcio** (externí)	široká funkcionalita

- Podpora pro získávání dat z ostatních služeb

Protokol	Modul	Popis
FTP, FTPs	**ftplib** (vestavěný)	kompletní funkcionalita
	requests_ftp (externí)	základní funkcionalita, API kompatibilní s requests
SSH, SFTP	**paramiko** (externí)	široká funkcionalita
WebSocket	**websockets** (externí)	široká funkcionalita, asynchronní zpracování

Získávání dat s využitím urllib.request

- Funkce modulu vrací objekt typu HTTPResponse (viz dokumentace)
  - HTTPResponse se chová jako soubor (je iterovatelný, lze jej použít jako context manager)
- Základní použití:
  - metoda GET

```
with urllib.request.urlopen('http://httpbin.org/get?param1=value1', timeout=10) as f:
     f.read(100).decode('utf-8')
     for x in iter(f):
         print(x)
```

  - metoda POST

```
with urllib.request.urlopen('http://httpbin.org/post', data=b'post data') as f:
     print(f.read().decode('utf-8'))
```

- Upřesnění dotazu pomocí třídy Request

```
req = urllib.request.Request(url='http://httpbin.org/headers', method='GET',
          headers={'User-Agent': 'Mozilla/5.0 (X11; Linux x86_64) …'})
with urllib.request.urlopen(req) as f:
    print(f.read().decode('utf-8'))
```

Získávání dat s využitím urllib.request

- Autentizace (BasicAuth, DigestAuth)

```
import urllib.request

auth_handler = urllib.request.HTTPBasicAuthHandler()
auth_handler.add_password(realm='Fake Realm', #viz WWW-Authenticate: Basic realm="Fake Realm"
                          uri='httpbin.org',
                          user='user',
                          passwd='p4ssw0rd')
opener = urllib.request.build_opener(auth_handler)
urllib.request.install_opener(opener)

with urllib.request.urlopen('https://httpbin.org/basic-auth/user/p4ssw0rd') as f:
    print(f.read())
```

- Persistence cookies

```
import os, http.cookiejar, urllib.request
cj = http.cookiejar.MozillaCookieJar()
cj.load(os.path.join(os.path.expanduser("~"), "path", "cookies.txt"))
opener = urllib.request.build_opener(urllib.request.HTTPCookieProcessor(cj))
# urllib.request.install_opener(opener)

with opener.open("https://httpbin.org/cookies/set?cookie1=value1") as f:
    print(f.read().decode('utf-8'))
```

Získávání dat s využitím modulu requests

- Requests nabízí oproti vestavěnému modulu propracovanější API a širší funkcionalitu
- Výčet vlastností z dokumentace:
  - Keep-Alive & Connection Pooling (hlavička Connection)
  - International Domains and URLs
  - Sessions with Cookie Persistence
  - Browser-style SSL Verification (incl. Client side certificates)
  - **Automatic Content Decoding** (hlavička Content-Type; text/html, text/json, …)
  - Basic/Digest Authentication (hlavička WWW-Authenticate; basic, digest, bearer, …)
  - Elegant Key/Value Cookies (hlavičky Set-Cookie, Cookie)
  - **Automatic Decompression** (hlavička Content-Encoding; gzip, deflate, br, …)
  - **Unicode Response Bodies**
  - HTTP(S) Proxy Support
  - **Multipart File Uploads** (hlavička Content-Type: multipart/form-data)
  - **Streaming Downloads**
  - Connection Timeouts
  - **Chunked Requests** (hlavička Transfer-Encoding; chunked)

Získávání dat s využitím requests

- Příklady použití:
  - metoda GET

```
resp = requests.get('https://httpbin.org/get', params={'param1':'value1'})
resp.status_code
print(resp.text)
```

  - metoda POST

```
resp = requests.post('https://httpbin.org/post', data={'param2':'value2'})
print(resp.text)
```

  - hlavičky

```
resp = requests.get('https://httpbin.org/headers', headers={'User-Agent': 'XYZ'})
resp.headers.get('content-type')
print(resp.text)
```

  - metody pro konverzi výstupu:

```
jsn = requests.get('https://httpbin.org/get', params={'param1':'value1'}).json()
#jsn['args']['param1']
```

Autentizace v request

- Nejběžnější podporované metody autentizace
  - HTTP Basic, HTTP Digest, OAuth1, případně OAuth2 prostřednictvím balíku **requests-oauthlib**
- Příklady:
  - HTTP Basic

```
from requests.auth import HTTPBasicAuth
with requests.get('https://httpbin.org/basic-auth/user/p4ssw0rd',
                  auth=HTTPBasicAuth('user', 'p4ssw0rd')) as f:
    print(f.json())
```

  - HTTP Basic je výchozí způsob autentizace

```
requests.get('https://httpbin.org/basic-auth/user/p4ssw0rd',
             auth=('user', 'p4ssw0rd'))
        .json()
```

  - autentizace pro více volání s využitím requests.Session

```
s = requests.Session()
s.auth = ('user', 'p4ssw0rd')
s.get('https://httpbin.org/basic-auth/user/p4ssw0rd').json()
s.get('https://httpbin.org/get').json()
```

Cookies v requests

- Persistence cookies
  - objekt Session uchovává cookies automaticky (viz atribut s.cookies)

```
with requests.Session() as s:
    s.get('https://httpbin.org/cookies/set?cookie1=value1')
    print(s.cookies) #<RequestsCookieJar[<Cookie cookie1=value1 for httpbin.org/>]>
    print(s.get('https://httpbin.org/cookies').json()) #{'cookies': {'cookie1': 'value1'}}
    print(requests.get('https://httpbin.org/cookies').json()) #{'cookies': {}}
```

  - jako úložiště lze použít výchozí **requests.cookies.RequestsCookieJar**

```
jar = requests.cookies.RequestsCookieJar()
jar.set('mycookie', 'value', domain='httpbin.org', path='/cookies')
with requests.Session() as s:
    s.cookies = jar
    print(s.get('https://httpbin.org/cookies').json()) #{'cookies': {'mycookie': 'value'}}
    print(requests.get('https://httpbin.org/cookies', cookies=jar).json())  #{'cookies': {'mycook
```

  - nebo jiného správce, např. **http.cookiejar.MozillaCookieJar** (viz př. **urllib**) nebo **http.cookiejar.LWPCookieJar**

```
with requests.Session() as s:
    s.cookies = http.cookiejar.LWPCookieJar("cookies.txt")
    s.get("https://google.com")
    s.cookies.save()
    s.cookies.load()
```

Získávání dat s využitím requests

- Podpora pro práci s objemnými daty
  - **upload** (vstupem může být generátor, iterátor, tj. i soubor)

```
with open('file.bin', 'rb') as f:
    requests.post('http://some.url/streamed', data=f)
```

```
def gendata():
    yield b'abc'
    yield b'def'
requests.post('https://httpbin.org/post', data=gendata()).json()
```

  - **download** (stream režim, vhodné na multimediální soubory)

```
with requests.get('https://httpbin.org/stream/100', stream=True) as r:
```

```
    for chunk in r:
        print(chunk)
```

```
    for chunk in r.iter_content(chunk_size=128, decode_unicode=True):
        fp.write(chunk)
```

```
    for line in r.iter_lines():
        print(line)
```

Transparentní cache

- Možnosti realizace transparentní cache
  - Jednoduchá perzistentní cache paměť pomocí rozšíření requests_cache (viz dokumentace)

```
import requests, requests_cache
requests_cache.install_cache('cache_filename')
for i in range(10):
    resp = requests.get('https://httpbin.org/delay/1')
    print(resp.from_cache)
```

  - Plnohodnotná stavová HTTP cache pomocí rozšíření CacheControl (viz dokumentace)

```
import requests
from cachecontrol import CacheControl
from cachecontrol.caches.file_cache import FileCache

sess = requests.session()
with CacheControl(sess, cache=FileCache('cache_dir')) as cs:
    for i in range(10):
        resp = cs.get('https://www.google.com/tia/tia.png')
        print(resp.from_cache)
```

Příklad na využití dekorátoru (zjednodušený)

```
import requests, time
```

```
def retry(tries, debug=False):
    def wrapper(f):
        def inner(*args, **kwargs):
            for t in range(1,tries+1):
                if t>1: time.sleep(1)
                try:
                    if debug: print(f'pokus #{t}')
                    return f(*args, **kwargs)
                except requests.HTTPError as err:
                    if debug: print(f'')
                    if (t == tries):
                        raise err
        return inner
    return wrapper
```

```
@retry(tries=3, debug=True)
def download():
    with requests.get('http://httpbin.org/status/404,403,200', timeout=10) as f:
        f.raise_for_status()
        print(f.status_code, f.raw.read())

download()
```

Formáty dat a jejich zpracování

HTML, XHTML, JSON, XML, CSV, XLSX, XLS, …

Formáty pro výměnu dat

- Podpora pro manipulaci s textovými formáty dat

Formát	Modul	Popis
CSV, TSV	**csv** (vestavěný)	načítání a ukládání dat z/do CSV
HTML/XHTML	**html.parser** (vestavěný)	čistě parser generující události
HTML/XHTML/XML	**beautifulsoup4** (externí)	pokročilé API, práce s nevalidním vstupem
XML	**xml.etree.ElementTree** (vestavěný)	načítání, manipulace, ukládání XML
	lxml (externí)	alternativa pro manipulaci s velkými soubory
JSON	**json** (vestavěný)	načítání a ukládání dat
XLSX	**openpyxl** (externí)	načítání, manipulace, ukládání Excel 2010+

- Binární formáty dat

Formát	Modul	Popis
XLS	**xlrd, xlwr** (externí)	načítání, manipulace, ukládání Excel 2007
	pyexcel (externí)	univerzální framework pro CSV,XLS,XLSX
PDF	**PyPDF2** (externí)	načítání, manipulace, ukládání
další	**struct** (vestavěný), externí **protobuf**, **pyarrow** (Apache Parquet), **h5py** (HDF5), …	

Zpracování CSV

- Typická sekvence při zpracování dat s využitím vestavěného modulu csv
  - otevření souboru

```
import csv
with open('dotaznik.csv', encoding="utf-8") as csvfile:
```

  - vytvoření readeru; automatická detekce nastavení parametrů (nemusí vždy fungovat), nebo

```
    dialect = csv.Sniffer().sniff(csvfile.read(1024))
    csvfile.seek(0)
    reader = csv.reader(csvfile, dialect)
```

  - vytvoření readeru; manuální konfigurace

```
    reader = csv.reader(csvfile, delimiter=',', quotechar='"')
```

  - zpracování vstupu do slovníku

```
    header = next(reader) #hlavicka
    for row in reader:
        row = dict(zip(header,row))
        ...
```

Zpracování HTML a XML

- Modul beautifulsoup4 umožňuje parsovat, procházet a modifikovat HTML/XML strom

```
from bs4 import BeautifulSoup    #%pip install beautifulsoup4
soup = BeautifulSoup("<html><body>a <b style=xyz>web</b> page<b class=a> 2</b></html>", 'html.parser')
```

- Základní operace:
  - pohyb po stromu

```
assert(soup.body == soup.find('body'))
assert(soup.b == soup.find('b'))
assert(soup.b.parent == soup.body)
assert(soup.b.next_sibling == ' page')
assert(soup.b.previous_sibling == 'a ')
```

  - přístup k atributům

```
assert(soup.b['style'] == 'xyz')
```

  - přístup k obsahu

```
assert(soup.body.text == 'a web page 2')
```

  - vyhledávání

```
soup.find('b',class_='a')
soup.find_all('b', style=lambda val: val=='xyz')
soup.find_all(string=re.compile("e|g")) # podle obsahu ['web', ' page']
soup.select(".a") #CSS selektory
```

  - modifikace stromu viz dokumentace
  - generování výstupu viz dokumentace

Serializace dat a datová persistence

Souborová úložiště, databázové systémy

Možnosti serializace a datové persistence

- Data malého a středního objemu, heterogenní data
  - Formát PICKLE pokud potřebujeme serializovat Python objekty
  - Formát CSV / JSON pokud potřebujeme přenositelnost mezi jazyky
    (extrakce dat z JSON lze např. pomocí jmespath, pyjsonq, dotazování např. pomocí pythonql3)
- Data velkého objemu, převážně n-dimensionální numerická uniformní pole
  - sloupcově orientované úložiště Apache Parquet (viz pyarrow.parquet a dokumentace)
  - hierarchické datové úložiště HDF5 (viz h5py) nebo lépe Zarr (viz zarr) nepotřebujeme-li přenositelnost
- Databázové systémy, pokud potřebujeme provádět dotazy
  - lokální souborově orientované DB
    - SQLite3 – vestavěný modul sqlite3
  - serverově orientované relační DB
    - PostgreSQL – externí modul psycopg,
    - MySQL – externí modul mysql-client, mysql-connector-python, …
    - nebo všechny výše uvedené pomocí vysokoúrovňového API (např. sqlobject, sqlalchemy, …)
  - serverově orientované NoSQL DB
    - MongoDB – externí modul pymongo

Serializace dat

```
import pickle, datetime, json
```

- Pomocí vestavěného modulu pickle (jakékoliv Python objekty)

```
data = {'num':123,
        10: [1, 2, 3, "x", None,
        datetime.datetime.now()]}
```

  - serializace do řetězce

```
serialized_data = pickle.dumps(data)
data = pickle.loads(serialized_data)
```

  - serializace do souboru

```
with open('data.pkl','wb') as f:
    pickle.dump(data, f)
    pickle.dump(data2, f)

with open('data.pkl','rb') as f:
    data = pickle.load(f)
    data2 = pickle.load(f)
```

- Pomocí vestavěného modulu json (pouze serializovatelná data)

```
data = {'num':123,
        10:[1, 2, 3, "x", None,
        int(datetime.datetime
            .now().timestamp())]}
```

  - serializace do řetězce

```
serialized_data=json.dumps(data)
json.loads(serialized_data)
```

  - serializace do souboru

```
with open('data.jsn','wt') as f:
    json.dump(data, f)
with open('data.jsn','rb') as f:
    data = json.load(f)
```

? proč nefunguje po načtení přístup k data[10]?

Redukce velikosti dat pomocí bezeztrátové komprese

principy viz předmět KKO

Podpora kompresních formátů

Formát	Modul	Popis
GZIP	**gzip** (vestavěný)	základní kompresní metoda využívající algoritmus DEFLATE (LZ77+Huffman)
BZIP2	**bz2** (vestavěný)	vyšší kompresní poměr oproti DEFLATE díky BWT (100-900kB), ale pomalejší
XZ	**lzma** (vestavěný)	lepší kompresní poměr než BZIP2, varianta LZ7 + range encoding, 4GB slovník
LZO	**python-lzo** (externí)	účinnost podobná DEFLATE, avšak mnohem rychlejší komprese i dekomprese
zlib	**zlib** (vestavěný)	Implementace DEFLATE bez kontrolních mechanismů

Podpora archivace souborů

Formát	Modul	Popis
ZIP	**zipfile** (vestavěný)	archivace souborů pomocí metod STORE, DEFLATE a případně BZIP2, LZMA
TAR	**tarfile** (vestavěný)	spojení souborů, komprese probíhá až následně (tar.gz, tar.bz2, tar.xz)
RAR	**rarfile** (externí)	není nativní podpora, založeno na volání externí aplikace (není open source)

* modul **patool** nabízí univerzální interface na různé externí archivační utility

Využití komprese pro redukci velikosti serializovaných dat

- Serializovaná data (JSON, Pickle, XML, …) je vhodné komprimovat

```
import json, gzip, bz2, lzma, datetime
data = {'num':123, 10:[1,2,3,"x",None,int(datetime.datetime.now().timestamp())]}
```

  - komprese dat při ukládání

```
with gzip.open('data.jsn.gz','wt') as f:
    json.dump(data, f, indent=4)
with bz2.open('data.jsn.bz2','wt') as f:
    json.dump(data, f, indent=4)
with lzma.open('data.jsn.xz','wt') as f:
    json.dump(data, f, indent=4)
```

  - načítání komprimovaných dat

```
with gzip.open('data.jsn.gz','rt') as f:
    data = json.load(f)
with bz2.open('data.jsn.bz2','rt') as f:
    data = json.load(f)
json.load(gzip.open('data.jsn.gz','rt'))
json.load(bz2.open('data.jsn.bz2','rt'))
json.load(lzma.open('data.jsn.xz','rt'))
```

```
import zipfile
```

Princip práce se ZIP archivem

- Vytvoření archivu

```
with zipfile.ZipFile('archiv.zip', 'w') as zf:
    for fn in range(0, 10):
        zi = zipfile.ZipInfo(f'file{fn:05d}.txt')
        zi.compress_type=zipfile.ZIP_DEFLATED #nebo ZIP_STORED, ZIP_BZIP2, ZIP_LZMA
        with zf.open(zi, mode='w') as dest:
            dest.write(bytes(f'obsah souboru {zi.filename}\r\n', encoding='ascii'))
            dest.write(b'A'*1_000_000)
```

- Přístup k souborům v archivu

```
with zipfile.ZipFile('archiv.zip', 'r') as zf:
    print(zf.namelist()) #seznam souborů v archivu
    with zf.open('file00000.txt','r') as f:
        print(f.readline()) #b'obsah souboru file00000.txt\r\n'
```

- Přidání souboru do archivu

```
with zipfile.ZipFile('archiv.zip', 'a') as zf:
    with zf.open('newfile.txt', mode='w') as dest:
        dest.write(b'X'*1_000_000)
```

Porovnání variant archivačních balíků

- Benchmark: 100 souborů o velikosti 10 MB, 16 kB bloky stejných / náhodných symbolů, SSD disk
- Operace: vytvoření archivu (přímé z generátoru, žádné mezisoubory)

archiv	komprese	uniformní data		náhodná data	
		doba vytváření	velikost archivu	doba vytváření	velikost archivu
tar	-	1.6	1 000 099 840	5.3	1 000 099 840
	GZIP	11.4	1 093 813	36.4	1 000 322 739
	BZIP2	11.2	25 299	172.0	1 004 425 810
	LZMA	18.6	151 764	409.2	1 000 138 832
zip	STORED	2.4	1 000 011 522	6.0	1 000 011 522
	DEFLATED	13.1	1 095 830	34.9	1 000 317 022
	BZIP2	13.0	93 032	150.6	1 004 460 785
	LZMA	24.9	180 102	322.4	1 013 606 521

Porovnání variant archivačních balíků

- Benchmark: 100 souborů o velikosti 10 MB, 16 kB bloky stejných / náhodných symbolů, SSD disk
- Operace: čtení dat z archivu (přímé, žádné mezisoubory)

archiv	komprese	uniformní data			náhodná data		
		list files	read first	read last	list files	read first	read last
tar	-	0.005	0.011	0.017	0.007	0.014	0.012
	GZIP	4.328	5.330	5.242	2.042	3.095	3.191
	BZIP2	3.013	3.397	3.454	96.549	89.709	98.493
	LZMA	1.485	1.895	1.690	2.109	2.758	2.850
zip	STORED	0.003	0.022	0.081	0.003	0.023	0.018
	DEFLATED	0.003	0.059	0.063	0.003	0.031	0.026
	BZIP2	0.003	0.072	0.071	0.004	0.990	0.876
	LZMA	0.003	0.058	0.054	0.002	0.626	0.657

Porovnání variant archivačních balíků

- Vlastnosti archivačních formátů ZIP a TAR
  - Oba formáty umožňují archivaci více souborů
  - Oba formáty umožňují rychlé přidání nových dat na konec souboru
  - ZIP umožňuje rychlý přístup ke kterémukoliv souboru kdykoliv, TAR pouze pokud není aplikována dodatečná komprese (penalizace velikosti několik řádů!! 3 ms vs 96 s)

- Manipulace s archivy v Python
  - Práce s TAR není příjemná: neexistuje API pro přímý přístup do TAR. Je zapotřebí přistupovat přes objekt fileobj s tím, že je nutné znát strukturu TAR (padding) a velikost dat předem.
  - Podpora komprese u TAR u objektově orientovaného rozhraní je krkolomná

- Pozor na metodu seek u archivu ZIP a TAR

HDF5 (Hierarchical Data Format)

- Přenosný hierarchichý datový formát, navržený pro uchovávání a organizaci velkého množství numerických dat.
  - HDF5 = **virtuální souborový systém v jednom souboru**
  - Umožnuje vytvářet v rámci souboru skupiny (groups) datových bodů (dataset), které kromě dat obsahují veškeré metainformace potřebné k interpretaci dat (self-describing format).
  - Rychlý přístup k datům (podpora pro extrahování částí číselných řad)
  - Přímá podpora v NumPy

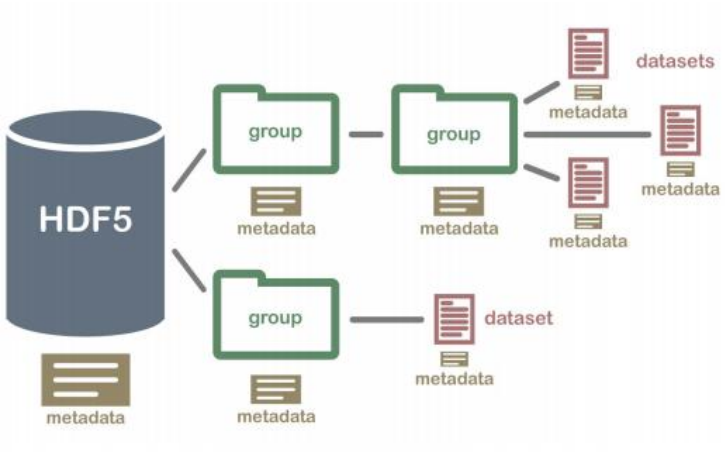

- Organizace dat
  - datové body lze organizovat hierarchicky do skupin
  - datové body určitého datového typu tvoří tzv. dataset – viz (shape, size, dtype) v NumPy array
- Dataset
  - dataset může být uložen v souboru kontinuálně nebo po souvislých blocích (tzv. chunk režim, který umožňuje kompresi) přičemž v druhém případě se přístup udržuje přes B-tree
  - velikost datasetu může růst pokud je tak specifikováno při jeho vytváření
  - řetězce a nenumerická data sice lze uložit, ale … viz dokumentace

```
import h5py
```

Hierarchický formát HDF5

- Ukázka práce s HDF5 pomocí externího modulu h5py (více viz dokumentace)
  - pořízení dat

```
with h5py.File('mytestfile.hdf5', 'w') as f:
    grp = f.create_group("subgroup")

    dset = grp.create_dataset("mydataset", (10_000_000,), dtype='int64')
    dset[:] = 12345

    dset = grp.create_dataset("mydataset_chunked", (10_000_000,), dtype='int64,,
                              chunks=(10_000,))
    dset[1000:] = 12345

    dset = grp.create_dataset("mydataset_chunked2", (10_000_000,), dtype='int64',
                              chunks=(10_000,), compression="gzip", compression_opts=9)
    dset[-1000:] = 12345
```

  - přístup k datům

```
f = h5py.File('mytestfile3.hdf5', 'r')
print(f['subgroup']['mydataset_chunked2'][9_000_000])
f.close()
```

Zarr

- Hierarchický datový formát určený pro prostředí Python navržený pro uchovávání a organizaci velkého množství numerických dat
  - škálovatelný formát
  - oproti HDF5 jde o aktivní a nový projekt s moderními prvky
  - podpora více vláken (navržen pro paralelní výpočty) vs jedno vláknový HDF5
  - snadné prototypování filtrů a rozšíření v jazyce Python
- Možnosti datové persistence
  - uchování dat v paměti (MemoryStore)
  - uchování dat na disku (DirectoryStore, TempStore, NestedDirectoryStore, ZipStore, DBMStore, LMDBStore)
  - uchování dat v DB (SQLiteStore, MongoDBStore, RedisStore)
  - uchování dat v cloudu (ABSStore, S3Map, …)
- Nenumerická data
  - řetězce jsou uchovávány podobně jako v HDF5, tj. buď jako pole bytů nebo jako datový typ **object** s filtrem VLenUTF8

Hierarchický formát Zarr

```
import zarr
```

- Ukázka práce s hierarchickým úložištěm Zarr (více viz dokumentace)
  - pořízení dat

```
with zarr.open('a.zarr', 'w') as root:

    grp = root.create_group('subgroup')
    N=100_000_000
    dset = grp.create_dataset(
        'mydataset',
        filters=[zarr.Delta(dtype='i8')],
        dtype='i8',
        shape=(N,),
    )
    dset[:] = [i for i in range(N)]
```

  - přístup k datům

```
with zarr.open('a.zarr', 'r') as root:
    i = 99_000_000
    print(root['subgroup']['mydataset'][i])
```

```
>> dset.info
```

Name	/subgroup/mydataset
Type	zarr.core.Array
Data type	int64
Shape	(100000000,)
Chunk shape	(195313,)
Order	C
Read-only	False
Filter [0]	Delta(dtype='<i8')
Compressor	Blosc(cname='lz4', clevel=5, shuffle=SHUFFLE
Store type	zarr.storage.MemoryStore
No. bytes	800000000 (762.9M)
No. bytes stored	3278174 (3.1M)
Storage ratio	244.0
Chunks initialized	512/512

Uchování dat v relační DB s využitím sqlalchemy

viz https://docs.sqlalchemy.org/en/13/orm/tutorial.html

```
from sqlalchemy import Column, Integer, String, create_engine
from sqlalchemy.ext.declarative import declarative_base
engine = create_engine('sqlite:///:memory:', echo=True) #'sqlite:///data.db'
```

```
MyDB = declarative_base()

class User(MyDB):
    __tablename__ = 'users'
    id = Column(Integer, primary_key=True)
    name = Column(String)
    fullname = Column(String)
    password = Column(String)
    def __repr__(self):
       return f"<User(name='{self.name}', fullname='{self.fullname}', password='{self.password}')>"

MyDB.metadata.create_all(engine)
```

```
session = sessionmaker(bind=engine)()
ed_user = User(name='ed', fullname='Ed Jones', password='edspassword')
session.add(ed_user)
session.commit()
user_by_email = session.query(User).filter(User.name=='ed').first()
print(user_by_email)
```